

MPI (Message Passing Interface)

Zbigniew Koza Wydział Fizyki i Astronomii

MPI

- MPI = Message Passing Interface
- Biblioteka i środowisko do programowania aplikacji współbieżnych w środowisku z pamięcią rozproszoną (*distributed memory*)



nttps://wcss.pl/images/image-01.jpg

Najprostszy program

```
#include <iostream>
#include <mpi.h>

int main(int argc, char* argv[])
{
    MPI_Init(&argc, &argv);
    int rank;
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    std::cout << "Hello! from process nr " << rank << "\n";
    MPI_Finalize();
}</pre>
```

Najprostszy program

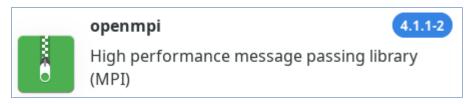
```
#include <iostream>
#include <mpi.h>

int main(int argc, char* argv[])
{
    MPI_Init(&argc, &argv);
    int rank;
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    std::cout << "Hello! from process nr " << rank << "\n";
    MPI_Finalize();
}</pre>
```

Instalacja

Zainstaluj jedną z bibliotek, np:

Open MPI



MPICH



Kompilacja

- > mpicxx prog.cpp -O2 ... c++
 > mpic++ prog.cpp -O2 ... c++
- > **mpicc** prog.c -O2 ...
- > **mpif90** prog.f90

FORTRAN 90

To są tzw. wrappery dla C++/C/F90

Uruchomienie

> mpirun -np 4 ./a.exe
> mpirun -np 10 --hosts master,slave1,slave2 ./a.exe
10 3 maszyny

procesów

(dobrze skonfigurowane)

Konfiguracja serwerów

Wspólny dysk sieciowy

```
zkoza@zwei ~ $ cat /etc/fstab
  /etc/fstab: static file system information.
                      - - -
/dev/sda1
                                      noauto, noatime
                 /boot
                            ext2
/dev/sda2
                            ext3
                                      noatime
/dev/sda3
                            swap
                 none
 /dev/sda5
                 /data
                            ext4
                                      noatime
zero:/home
                           nfs4
                 /home
                                      rw,quota
```

Konfiguracja serwerów

Konfiguracja ssh

- ssh-keygen
- -ssh-copy-id -i inny_serwer
- -ssh inny_serwer

Testy:

- -scp inny_serwer:zdalne_miejsce plik_lokalny
- -scp plik_lokalny inny_serwer:zdalne_miejsce
- ssh inny_serwer
- ssh inny_serwer komenda
- Pamiętaj o (ewentualnym) uruchomieniu serwisu sshd

Jak to działa?

- Ten sam program uruchamia się jako niezależne procesy jednocześnie na tej samej lub różnych maszynach
- Procesy synchronizują się poprzez tzw. komunikaty MPI
- Nie ma wspólnej pamięci
 - MPI funkcjonuje w modelu pamięci rozproszonej

Jak to działa?

Uruchom n kopii programu; na każdej z nich:

Wypełnij bufor danych

Wypełnij bufor danych

Pobierz swój id w grupie n procesów

Pobierz swój id w grupie n procesów

Jeżeli (my_id == 0)

Wyślij dane do procesu o id == 1

Jeżeli (my_id == 1)

Odbierz dane z procesu o id == 0

Jeżeli (my_id == 0)

Wyślij dane do procesu o id == 1

Jeżeli (my_id == 1)

Odbierz dane z procesu o id == 0

Zakończ pracę w trybie MPI

Uruchom n kopii programu; na każdej z nich:

Wypełnij bufor danych

Wypełnij bufor danych

Pobierz swój id w grupie n procesów

Pobierz swój id w grupie n procesów

 $Jeżeli (my_id == 0)$

Wyślij dane do procesu o id == 1

Jeżeli (my_id == 1)

Otwórz bufor na dane z id == 0

Rób_coś()

Jeżeli (my_id == 0)

Poczekaj na koniec transmisji do 1

Jeżeli (my_id == 1)

Poczekaj na koniec transmisji z 0

Jeżeli (my_id == 0)

Wyślij dane do procesu o id == 1

Jeżeli (my_id == 1)

Otwórz bufor na dane z id == 0

Rób_coś()

Jeżeli (my_id == 0)

Poczekaj na koniec transmisji do 1

Jeżeli (my_id == 1)

Poczekaj na koniec transmisji z 0

Zakończ pracę w trybie MPI

Uruchom n kopii programu; na każdej z nich:



Pobierz swój id w grupie n procesów

Oblicz f(id) i wynik zapisz w k

Oblicz f(id) i wynik zapisz w k

Jeżeli (my_id == 0)
Odbierz k od każdego procesu
Zapisz ich sumę w swoim k
W przeciwnym wypadku
Wyślij k do procesu o id == 0

Jeżeli (my_id == 0)
Odbierz k od każdego procesu
Zapisz ich sumę w swoim k
W przeciwnym wypadku
Wyślij k do procesu o id == 0

Zakończ pracę w trybie MPI

Uruchom n kopii programu; na każdej z nich:

Pobierz swój id w grupie n procesów

Pobierz swój id w grupie n procesów

Wypełnij swój bufor (id)

Wypełnij swój bufor (id)

Jeżeli (my_id == 0)
Odbierz bufor od każdego procesu
Dane zapisz w swoim n-razy
większym buforze
W przeciwnym wypadku
Wyślij bufor do procesu o id == 0

Jeżeli (my_id == 0)
Odbierz bufor od każdego procesu
Dane zapisz w swoim n-razy
większym buforze
W przeciwnym wypadku
Wyślij bufor do procesu o id == 0

Zakończ pracę w trybie MPI

Prosty przykład

MPI_Send/MPI_Recv

```
MPI_Init(NULL, NULL);
int world_rank, world_size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Musza istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
 MPI Abort(MPI COMM WORLD, 1);
int number;
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
 MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
 MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI_Finalize();
```

Inicjalizacja / finalizacja

```
MPI_Init(NULL, NULL);
int world_rank, world_size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Musza istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
  MPI Abort(MPI COMM WORLD, 1);
int number;
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
  MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
  MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI Finalize();
```

Kim jestem? / Ilu nas jest?

```
MPI_Init(NULL, NULL);
int world rank, world size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Musza istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
  MPI Abort(MPI COMM WORLD, 1);
int number;
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
  MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
  MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI_Finalize();
```

Czy nie jestem sam?

```
MPI_Init(NULL, NULL);
int world rank, world size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Muszą istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
  MPI Abort(MPI COMM WORLD, 1);
int number;
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
  MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
  MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI Finalize();
```

Proces nr 0 ("master") wysyła dane

```
MPI_Init(NULL, NULL);
int world_rank, world_size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Musza istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
  MPI Abort(MPI COMM WORLD, 1);
int number:
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
  MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
  MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI_Finalize();
```

Proces nr 1 ("slave") odbiera dane

```
MPI_Init(NULL, NULL);
int world_rank, world_size; // id procesu; liczba procesów
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI Comm size(MPI COMM WORLD, &world size);
if (world size < 2) // Musza istnieć co najmniej dwa procesy
  fprintf(stderr, "World size must be greater than 1 for %s\n", argv[0]);
  MPI Abort(MPI COMM WORLD, 1);
int number;
if (world_rank == 0)
  // Jeżeli proces ma rank 0, to wysyła liczbę -1 do procesu 1
  number = -1;
  printf("Process 0 is sending an int of value %d\n", number);
  MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
else if (world_rank == 1)
  MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
  printf("Process 1 received number %d from process 0\n", number);
MPI_Finalize();
```

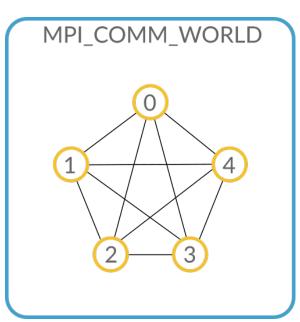
MPI_COMM_WORLD

- Tzw. komunikator
- Argument niemal każdej funkcji MPI
- Oznacza wszystkie uruchomione procesy

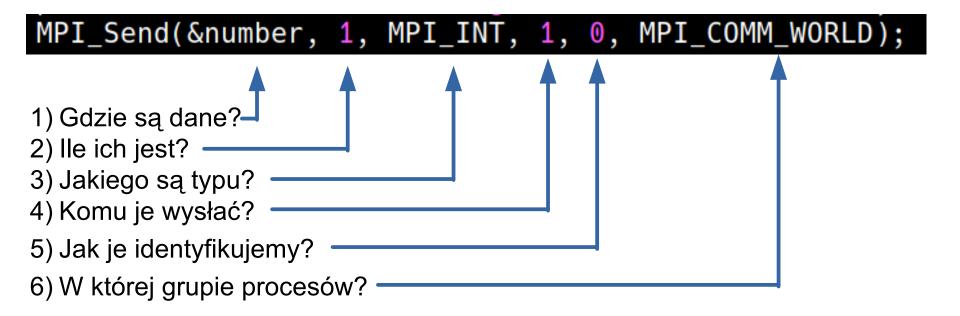
```
MPI_Comm_rank(MPI_COMM_WORLD, &world_rank);
MPI_Comm_size(MPI_COMM_WORLD, &world_size);

MPI_Abort(MPI_COMM_WORLD, 1);

MPI_Send(&number, 1, MPI_INT, 1, 0, MPI_COMM_WORLD);
```



MPI_Send



```
int MPI_Send(const void* buf,
    int count,
    MPI_Datatype datatype,
    int dest,
    int tag,
    MPI_Comm comm)
```

MPI_Recv

```
MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
 1) Gdzie umieścić dane?
 2) lle ich jest?
 3) Jakiego są typu?
 4) Kto je ma wysłać?
 5) Jaki mają mieć identyfikator?
 6) W której grupie procesów?
 7) Jak operacja się zakończyła?
  int MPI Recv(void
                              *buf,
                int
                              count,
                MPI_Datatype datatype,
                int
                              source,
                int
                              tag,
                MPI Comm
                              comm,
                MPI Status*
                              status)
```

MPI_Send/MPI_Recv

MPI_Send i MPI_Recv
 są operacjami blokującymi

MPI_Isend/MPI_Irecv

- Istnieją analogiczne operacje nieblokujące,
 MPI_Isend, MPI_Irecv
- Używa się ich z funkcjami
 MPI_Test lub MPI_Wait, MPI_Waitall
- Przesyłanie danych odbywa się w tle, program może zajmować się czymś innym

Przykład

```
MPI_Request requests[2];
 double k = 5* my_rank;
 std::array<double,5> a = \{k, 1+k, 2+k, 3+k, 4+k\}, b = \{0, 0, 0, 0, 0\};
   (my_rank == 0)
   MPI_Irecv(&b[0], 5, MPI_DOUBLE, 1, 1, MPI_COMM_WORLD, &requests[0]);
   MPI_Isend(&a[0], 5, MPI_DOUBLE, 1, 2, MPI_COMM_WORLD, &requests[1]);
 else if (my_rank == 1)
   MPI_Irecv(&b[0], 5, MPI_DOUBLE, 0, 2, MPI_COMM_WORLD, &requests[0]);
   MPI_Isend(&a[0], 5, MPI_DOUBLE, 0, 1, MPI_COMM_WORLD, &requests[1]);
 print(my_rank, a, "a =");
print(my_rank, b, "b =");
std::cout << my_rank << " is waiting\n";</pre>
MPI_Waitall(2, requests, MPI_STATUSES_IGNORE);
                                                   my_rank: 0; a = 0 1 2 3 4
 print(my_rank, a, "a =");
                                                  my_rank: 0; b = 0 0 0 0 0
 print(my_rank, b, "b =");
                                                   0 is waiting
                                                   my_rank: 1; a = 5 6 7 8 9
                                                  my_rank: 1; b = 0 0 0 0 0
                                                   1 is waiting
                                                   my_rank: 0; a = 0 1 2 3 4
                                                   my_rank: 0; b = 5 6 7 8 9
                                                  my_rank: 1; a = 5 6 7 8 9
                                                  my_rank: 1; b = 0 1 2 3
```

Wyścig, zakleszczenie

- Wyścig (race) w MPI można uzyskać coś w rodzaju wyścigu, przedwcześnie używając bufory operacji nieblokujących
- Zakleszczenie (deadlock) można uzyskać niemal każdą funkcją MPI – to nieodłączna cecha programowania współbieżnego

```
#include <mpi.h>
#include <chrono>
#include <thread>
#include <iostream>
int main()
   int rank;
   int sendbuf = 12345;
   int recvbuf = 0;
   MPI Request request;
   MPI Init(nullptr, nullptr);
   MPI Comm rank(MPI COMM WORLD, &rank);
   if (rank == 0)
       MPI Isend(&sendbuf, 1, MPI INT, 1, 0, MPI COMM WORLD, &request);
   if (rank == 1)
       MPI Irecv(&recvbuf, 1, MPI INT, 0, 0, MPI COMM WORLD, &request);
   std::this thread::sleep for(std::chrono::seconds(2));
   std::cout << "rank = "<< rank << ", sendbuf = "<< sendbuf
             << ", recvbuf = " << recvbuf << "\n";
   MPI Finalize();
```

 Nie wiadomo, kiedy recvbuf zostanie zapisany

```
rank = 1, sendbuf = 12345, recvbuf = 0
rank = 0, sendbuf = 12345, recvbuf = 0
```

MPI_Test

- Funkcja nieblokująca
- Result != 0 oznacza, że MPI_Isend / MPI_Irecv zakończyła się powodzeniem

MPI_Wait



```
rank = 0, sendbuf = 12345, recvbuf = 0
rank = 1, sendbuf = 12345,_recvbuf = 12345
```

- Funkcja blokująca
- MPI_Isend / MPI_Irecv musisz zakończyć funkcją
 MPI_Wait (MPI_Waitall) lub MPI_Test

Zakleszczenie - przykład

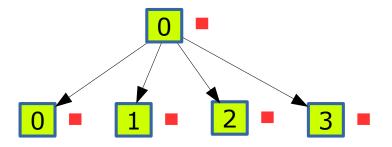
```
int number = 189;
if (world_rank == 0)
{
    // Proces 0 wysyła liczbę -1 do procesu 1 (ale tag == 1 - deadlock!)
    number = -1;
    printf("Process 0 is sending an int of value %d\n", number);
    MPI_Send(&number, 1, MPI_INT, 1, 1, MPI_COMM_WORLD);
}
else if (world_rank == 1)
{
    MPI_Recv(&number, 1, MPI_INT, 0, 0, MPI_COMM_WORLD, MPI_STATUS_IGNORE);
    printf("Process 1 received number %d from process 0\n", number);
}
```

- 0 wysyła komunikat nr 1
- 1 oczekuje na komunikat nr 0
- Efekt: zakleszczenie

MPI_Bcast

```
int main()
{
    MPI_Init(nullptr, nullptr);
    int rank;
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    int sendbuf = 1000 + rank;
    std::cout << "rank = "<< rank << ", sendbuf = "<< sendbuf << "\n";
    MPI_Bcast(&sendbuf, 1, MPI_INT, 0, MPI_COMM_WORLD);
    std::cout << "rank = "<< rank << ", sendbuf = "<< sendbuf << "\n";
    MPI_Finalize();
}</pre>
```

Broadcast = "rozgłaszanie"



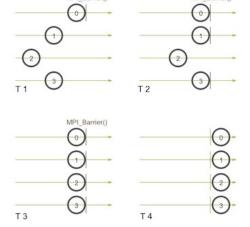


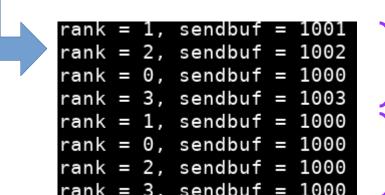
```
rank = 0, sendbuf = 1000
rank = 0, sendbuf = 1000
rank = 1, sendbuf = 1001
rank = 1, sendbuf = 1000
rank = 3, sendbuf = 1003
rank = 3, sendbuf = 1000
rank = 2, sendbuf = 1002
rank = 2, sendbuf = 1000
```

MPI_Barrier

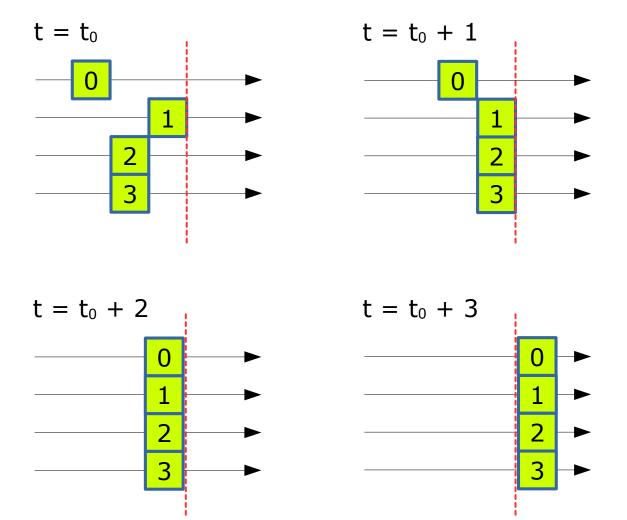
```
MPI_Init(nullptr, nullptr);
int rank;
MPI_Comm_rank(MPI_COMM_WORLD, &rank);
int sendbuf = 1000 + rank;
std::cout << "rank = "<< rank << ", sendbuf = "<< sendbuf << "\n";
MPI_Barrier(MPI_COMM_WORLD);
MPI_Bcast(&sendbuf, 1, MPI_INT, 0, MPI_COMM_WORLD);
std::cout << "rank = "<< rank << ", sendbuf = "<< sendbuf << "\n";
MPI_Finalize();</pre>
```

Bariera



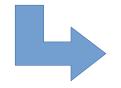


Bariera



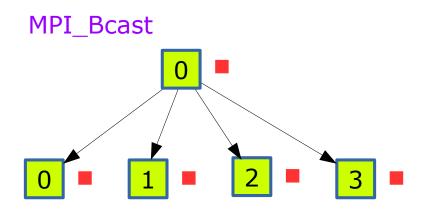
MPI_Scatter

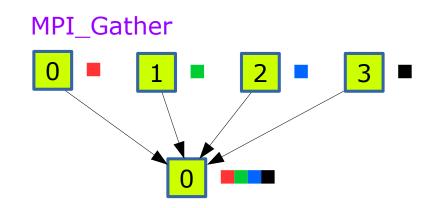
```
MPI_Init(nullptr, nullptr);
int rank, world size;
MPI Comm rank(MPI COMM WORLD, &rank);
MPI Comm size(MPI COMM WORLD, &world size);
std::vector<int> buffer;
if (rank == 0)
  buffer.resize(world size*2);
  std::iota(begin(buffer), end(buffer), 0);
int recvd[2] = \{-1, -1\};
MPI_Scatter(buffer.data(), 2, MPI_INT, recvd, 2, MPI_INT, 0, MPI_COMM_WORLD);
std::cout << "rank = "<< rank
          << ", received = " << recvd[0] << ", " << recvd[1] << "\n";</pre>
MPI_Finalize();
```

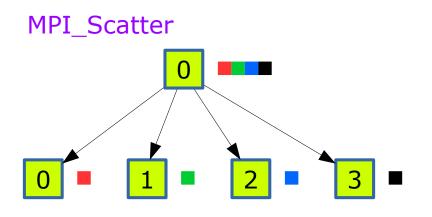


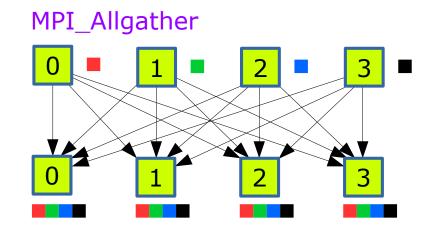
```
rank = 0, received = 0, 1 rank = 1, received = 2, 3
```

Broadcast, Scatter, Gather, Allgather

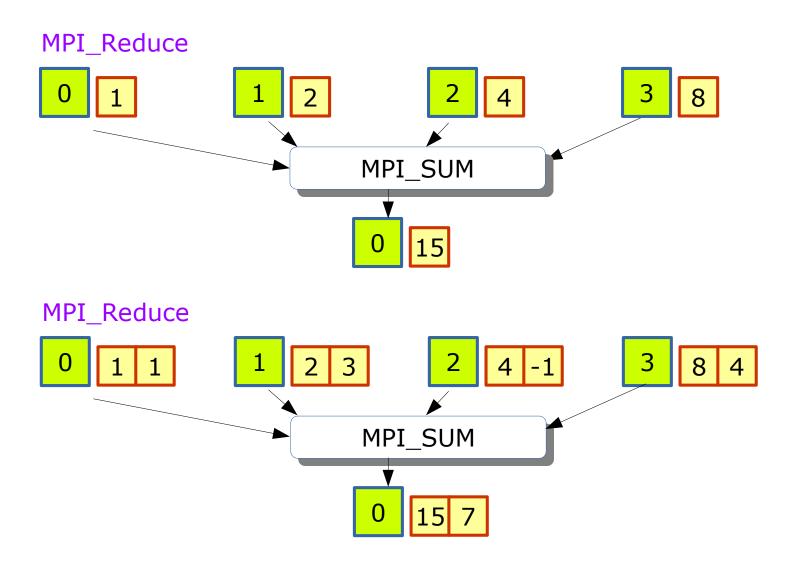




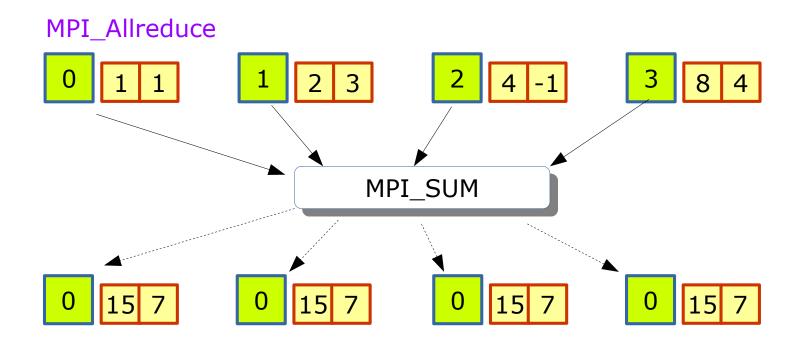




Reduce

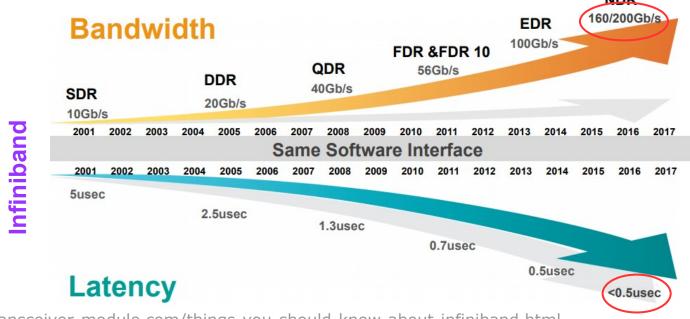


Allreduce

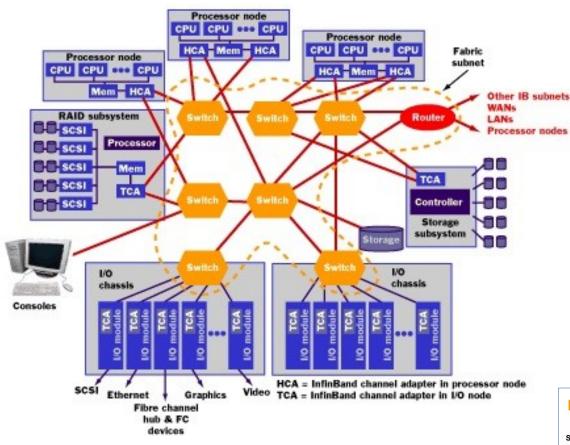


Latency i bandwidth

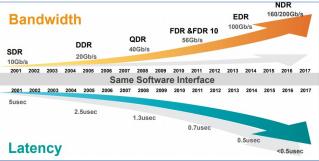
- Latencja: czas potrzebny do nawiązania połączenia i otwarcia kanału komunikacyjnego
- Przepustowość: prędkość transferu
 - Komunikaty MPI mogą być kosztowne



Latency i bandwidth



Infiniband

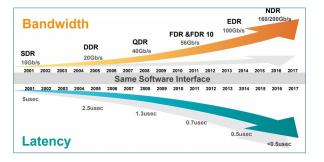


Latency i bandwidth

- Jeśli latencja = 1µs
 a przepustowość = 20GB/s, to
 - Przesłanie 1 bajta zajmuje 1 µs
 - Przesłanie 1 KB zajmuje 1.05 μs
 - Przesłanie 1 MB zajmuje 51 µs
 - Przesłanie 1 GB zajmuje 50 ms

latencja

przepustowość



OpenMP vs MPI

OpenMP

- Wbudowane w kompilator
- Dyrektywy, biblioteka,
 zmienne środowisk.
- Pamięć współdzielona
- Wątki
- Fork & join

MPI

- Biblioteka,(OpenMPI, MPICH,...)
- Biblioteka

- Pamięć rozproszona
- Procesy
- Procesy są tworzone raz

OpenMP vs MPI

OpenMP

- Prosta kompilacja (-fopenmp)
- Programyuruchamiane"normalnie"

MPI

- Nakładka na kompilator (mpic++, etc.)
- Specjalny program uruchomieniowy (mpirun)

OpenMP vs MPI

OpenMP

- Pamięć współdzielona
- Dane: prywatne i współdzielone
- Możliwy wyścig =>
 muteksy, sekcje
 krytyczne, operacje
 atomowe...

MPI

- Komunikaty (narzut)
- Dane: prywatne
- nie potrzeba muteksów etc.

Dalsza lektura

- https://mpitutorial.com/
- https://www.open-mpi.org/doc/current/
- https://www.codingame.com/playgrounds/349/

